



我们能看到的有限长的未来,但是面对无限多的问题。


We can only see a short distance ahead, but we can see plenty there that needs to be done.

—— 艾伦·图灵 (Alan Turing) | 英国计算机科学家、数学家,人工智能之父 | 1912 ~ 1954



- ◆ statsmodels.api.tsa.seasonal_decompose() 季节性调整
- ◀ numpy.random.uniform() 生成满足均匀分布的随机数
- ◀ df.ffill() 向前填充缺失值
- ◀ df.bfill() 向后填充缺失值
- ◀ df.interpolate() 插值法填充缺失值
- ✓ seaborn.boxplot() 绘制箱型图
- ◀ seaborn.lineplot() 绘制线图
- ◀ plotly.express.bar() 创建交互式柱状图
- ◀ plotly.express.box() 创建交互式箱型图
- ◀ plotly.express.pie() 创建交互式饼图
- ◀ plotly.express.scatter() 创建交互式散点图
- ◀ plotly.express.sunburst() 创建交互式太阳爆炸图





6.1 时间序列数据

时间序列是一种特殊的数据类型,它是某一特征在不同时间点上顺序观察值得到的序列。**时间戳** (timestamp) 可以精确到年份,月份,日期,甚至是小时、分、秒。




图 1. 时间轴

图 2 所示为 2020 年度中 9 支股票的每个营业日股价数据。图 2 中数据共有 253 行,每行代表一个日期及当日股价水平;共有 10 列,第 1 列为时间戳,其余 9 列每列为股价数据。除去时间戳一列和表头,图 2 可以看成一个矩阵。

Date	TSLA	TSM	COST	NVDA	FB	AMZN	AAPL	NFLX	GOOGL
2-Jan-2020	86.05	58.26	281.10	239.51	209.78	1898.01	74.33	329.81	1368.68
3-Jan-2020	88.60	56.34	281.33	235.68	208.67	1874.97	73.61	325.90	1361.52
6-Jan-2020	90.31	55.69	281.41	236.67	212.60	1902.88	74.20	335.83	1397.81
7-Jan-2020	93.81	56.60	280.97	239.53	213.06	1906.86	73.85	330.75	1395.11
8-Jan-2020	98.43	57.01	284.19	239.98	215.22	1891.97	75.04	339.26	1405.04
9-Jan-2020	96.27	57.48	288.75	242.62	218.30	1901.05	76.63	335.66	1419.79
21-Dec-2020	649.86	104.44	364.25	533.29	272.79	3206.18	128.04	528.91	1734.56
22-Dec-2020	640.34	103.55	361.32	531.13	267.09	3206.52	131.68	527.33	1720.22
23-Dec-2020	645.98	103.37	361.18	520.37	268.11	3185.27	130.76	514.48	1728.23
24-Dec-2020	661.77	105.57	363.86	519.75	267.40	3172.69	131.77	513.97	1734.16
28-Dec-2020	663.69	105.75	370.33	516.00	277.00	3283.96	136.49	519.12	1773.96
29-Dec-2020	665.99	105.16	371.99	517.73	276.78	3322.00	134.67	530.87	1757.76
30-Dec-2020	694.78	108.49	373.71	525.83	271.87	3285.85	133.52	524.59	1736.25
31-Dec-2020	705.67	108.63	376.04	522.20	273.16	3256.93	132.49	540.73	1752.64

图 2. 股票收盘股价数据

图 3 利用线图可视化股票收盘股价走势。图 3 (b) 右图初始股价归一化处理。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在B站——生姜 DrGinger: https://space.bilibili.com/513194466

欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com




图 3. 股票收盘股价走势, 和初始值归一化, 时间序列数据

本书后续会用到**收益率** (return) 这个概念。我们先介绍**损益** (Profit and Loss, PnL) 这个概念。如图 4 所示,只考虑收盘价 S 在 t 时刻和 t-1 时刻 (工作日) 的变动,通过如下公式计算出 t 时刻的日损益:

$$PnL_{t} = S_{t} - S_{t-1} \tag{1}$$




图 4. 某股票的价格变动

在不考虑**分红** (dividend) 的条件下,单日简单回报率 (daily simple return) 可以这样计算:

$$r_{t} = \frac{S_{t} - S_{t-1}}{S_{t-1}} \tag{2}$$

金融分析还经常使用日对数回报率 (daily log return):

$$r_{t} = \ln\left(\frac{S_{t}}{S_{t-1}}\right) \tag{3}$$

本书后续经常使用日对数收益率。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com 图 5 所示为一只股票在不同年份的日收益率分布,利用高斯分布估计样本分布多数情况下似乎是个不错的选择。图 6 所示为利用 KDE 估算得到概率密度。大家可以发现数据的统计量 (均值、方差、均方差、偏度、峰度) 随着时间变化。




图 5. 收益率数据山脊图, 按年分类




图 6. 收益率数据 KDE 山脊图,按年分类

鸢尾花数据,我们可以打乱数据的先后排列。但是时间序列是一个顺序序列,数据的先后顺序一般情况是不允许打乱的。有些情况,我们可以不考虑数据点的时间,比如图7所示回归分析。

本书第10、11章将介绍线性回归模型。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。代码及 PDF 文件下载: https://github.com/Visualize-ML




图 7. 线性 OLS 回归分析和散点图

6.2 处理时间序列缺失值

时间数据序列在分析建模之前,也需要注意数据中的缺失值和异常值处理。本书前文有专门章节介 绍如何处理缺失值和异常值。本节从时间序列角度加以补充缺失值处理。

前文强调,时间序列数据是顺序观察的数据;因此在处理缺失值时,有其特殊性。比如,时间序列数据可以采用均值、众数、中位数、插值等一般方法,也可以采用如向前、向后这种方法。




图 8. 处理缺失值

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466

图 9~图 11 所示为三种不同处理时间序列缺失值的基本方法。




图 9. 向前插值填充缺失值




图 10. 向后插值填充缺失值




图 11. 线性插值填充缺失值

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 成权归有平人字面版在所有,有勿向用,引用有压切面处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套徽课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com



Bk6_Ch6_01.ipynb 绘制图 9~图 11。

6.3 从时间数据中发现趋势

本节利用美国失业率数据介绍如何从时间数据中发现趋势。图 12 所示为失业率的原始数据。数据从 1950 年开始到 2021 年,每月有一个数据点。

观察图 12 这幅图,虽然存在"噪音",我们已经能够大致看到失业率的按照年份的大致走势。下一章会介绍移动平均的方法来消除"噪音"。

观察图 12 的局部图中,我们还发现不同年份中一年内失业率存在某种特定的"模式"。也就是说,图中的"噪音"可能存在重要的价值!

图 13 所示为按月同比规律。与历史同时期比较,例如 2005 年 7 月份与 2004 年 7 月份相比称其为同比。相比图 12、图 13 更容易发现失业率变化规律。




图 12. 原始失业率数据和局部放大图





图 13. 失业率,按月同比

图 14 所示为年内环比数据。与上一统计段比较,例如 2005 年 7 月份与 2005 年 6 月份相比较称其为环比。我们似乎发现失业率存在某种年度周期规律。一年之内春天的失业率往往较低,这似乎和春天农业生产用工有关。而每一年的一月份的失业率显著提高,这可能和圣诞节、新年节庆之后用工下降有关。

为了进一步看到失业率随年度变化,我们可以用箱型图对年内失业率数据加以归纳,如图 15 所示。箱型图的均值代表年度失业率的平均水平。箱型图的四分位间距 IQR 告诉我们年度失业率的变化幅度。显然,失业率在 2020 年出现"前所未闻"的大起大落。

图 16 所示为月份失业率箱型图。比较月份失业率的平均值变化,一月份的平均失业率确实陡然升高,这也印证了之前的猜测。下一节,我们就介绍如何将不同的成分从原始时间数据中分离出来。



本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466




图 15. 年度失业率数据箱型图




图 16. 月份失业率数据箱型图



Bk6_Ch6_02.ipynb 绘制本节图像。

6.4 时间序列分解

时间序列有如图 17 所示的几种主要的组成部分。具体定义如下:

- **趋势项** (trend component) *T(t)*,表征时间序列中确定性的非季节性长期总体趋势,通常呈现出线性或非线性的持续上升或者持续下降。当一个时间序列数据长期增长或者长期下降时,表示该序列有 趋势。在某些场合,趋势代表着"转换方向"。例如从增长的趋势转换为下降趋势。
- 季节项 (seasonal component) S(t),表征时间序列中确定性的周期季节性成分,是在连续时间内 (例如连续几年内) 在相同时间段 (例如月或季度) 重复性的系统变化。当时间序列中的数据受到季节性因

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。


代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466

欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

素(例如一年的时间或者一周的时间)的影响时,表示该序列具有季节性。季节性总是一个已知并 且固定的频率。

- 循环项 (long-run cycle component) C(t)。循环项代表是相对周期更长 (例如几年或者十几年) 的重复性 变化,但一般没有固定的平均周期,往往与大型经济体的经济周期息息相关。有时由于时间跨度较 短,循环项很难体现出来,这时可能就被当作趋势项来分析了。当时间序列数据存在不固定频率的 上升和下降时,表示该序列有 周期性 。这些波动经常由经济活动引起,并且与"商业周期"有关。周 期波动通常至少持续两年。
- **随机项** (stochastic component) I(t),表征时间序列中随机的不规则成分,体现出一定的自相关性以及 持续时间内无法预测的周期。该成分可以是噪声,但不一定是。往往认为随机项包含有与业务自身 密切相关的信息。



许多时间序列同时包含趋势、季节性以及周期性。基于以上的主要成分,一个时间序列可以有以下 几种组合模型。

加法模型

加法模型 (additive model),各个成分直接相加得到:

$$X(t) = T(t) + S(t) + C(t) + I(t)$$

$$\tag{4}$$

这可能是最常用的时间序列分解方式。如果一个时间序列仅仅由趋势项 T(t) 和随机项 I(t) 构成:

$$X(t) = T(t) + I(t)$$
(5)




图 18. 累加分解,原始数据 X(t)被分解为趋势成分 T(t)和噪音成分 I(t)

标普 500 指数长期来看随时间增长,按照经济周期涨跌,短期来看指数每天波动不止。长期趋势成分 T(t) 就可以描述这种时间序列的长期行为,而不规则成分 I(t) 描述的就是噪音成分,或者说是随机运动成分。




图 19. 累加分解,原始数据 X(t)被分解为趋势成分 T(t)、季节成分 S(t) 和噪音成分 I(t)

乘法模型

乘法模型 (multiplicative model),各个成分直接相乘得到:

$$X(t) = T(t) \cdot S(t) \cdot C(t) \cdot I(t)$$
(6)

如果只考虑趋势项 T(t) 和随机项 I(t):

$$X(t) = T(t) \cdot I(t) \tag{7}$$

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在B站——生姜 DrGinger: https://space.bilibili.com/513194466

欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com




图 20. 累乘分解,原始数据 X(t)被分解为趋势成分 T(t)和噪音成分 I(t)

考虑季节成分的乘法模型:




图 21. 累乘分解,原始数据 X(t)被分解为趋势成分 T(t)和噪音成分 I(t)

当然,时间序列还可以存在其他分解模型。比如**对数加法模型** (log-additive model),时间序列取对数后由各个成分相加得到:

$$\ln X(t) = T(t) + S(t) + C(t) + I(t) \tag{9}$$

相当于对 X(t) 进行对数转换。对于更复杂的时间序列分解模型,本书不做介绍。

季节调整

本例利用 scipy.stats.tsa.seasonal_decompose() 函数完成本章前文失业率数据的季节性调整。这个函数同时支持加法模型, seasonal_decompose(series, model='additive'), 和乘法模型, seasonal_decompose(series, model='multiplicative')。本节采用的是默认的加法模型。

本PDF文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。代码及PDF文件下载: https://github.com/Visualize-ML

图 22 所示为失业率数据的分解。图 22 (a) 为原始数据,图 22 (b) 为趋势成分,图 22 (c) 为季节成分,图 22 (d) 为噪音成分。注意,图 22 四副子图的纵轴尺度完全不同。图 23、图 24、图 25 三幅图分别展示这四种成分。

scipy.stats.tsa.seasonal_decompose() 函数采用比较简单卷积方法进行季节调整,对于更复杂的季节性调整,建议大家了解 X11,本书不做展开。






图 22. 失业率数据的分解




本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466







Bk6_Ch6_03.ipynb 绘制本节图像。

6.5 时间数据讲故事

《编程不难》介绍过如何采用"Pandas + Plotly"可视化数据讲故事,本节相当于是这个话题的延续。此外,本节内容也帮助大家复习 Pandas 数据处理和 Plotly 可视化方案。

本节采用的是 Plotly 提供的有关世界国家地区人口、预期寿命、人均 GDP 数据,这个数据集的导入方式为 plotly.express.data.gapminder()。表1 展示数据集的前 10 行数据;其中,lifeExp 代表预期寿命,pop 代表人口数,gdpPercap 代表人均 GDP。需要注意的是表1中数据时间采样为 5 年,也就是说每 5 年一个数据点。

表 1. Plotly 中世界国家地区人口、预期寿命、人均 GDP 数据集 (前 10 行)

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套徽课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

country_or_territory	continent	year	lifeExp	pop	gdpPercap	iso_alpha	iso_num
Afghanistan	Asia	1952	28.801	8425333	779.4453	AFG	4
Afghanistan	Asia	1957	30.332	9240934	820.853	AFG	4
Afghanistan	Asia	1962	31.997	10267083	853.1007	AFG	4
Afghanistan	Asia	1967	34.02	11537966	836.1971	AFG	4
Afghanistan	Asia	1972	36.088	13079460	739.9811	AFG	4
Afghanistan	Asia	1977	38.438	14880372	786.1134	AFG	4
Afghanistan	Asia	1982	39.854	12881816	978.0114	AFG	4
Afghanistan	Asia	1987	40.822	13867957	852.3959	AFG	4
Afghanistan	Asia	1992	41.674	16317921	649.3414	AFG	4
Afghanistan	Asia	1997	41.763	22227415	635.3414	AFG	4

人口

下面,让我们先完成人口相关的数据分析和可视化。

图 26 用堆积柱状图可视化各大洲人口数量随年份变化。Bk6_Ch6_04.ipynb 还给出用线图完成相同数据的可视化。请大家回顾如何调整 Plotly 图像风格。




图 26. 各大洲人口随年份 (每 5 年) 变化, 堆积柱状图

有些时候,我们还会关注各大洲人口占比,图 27 用堆积柱状图可视化人口比例随年份变化。Bk6_Ch6_04.ipynb 还给出用面积图完成相同数据的可视化。

为了看清各大洲人口占比随时间变化,我们还可以用图 28 线图进行可视化。




图 27. 各大洲人口占比随年份变化,堆积柱状图




图 28. 各大洲人口占比随年份变化,线图

如果关系某年度的各大洲的人口占比, 我们还可以用甜甜圈图 (饼图的变形)。图 29 所示为 2007 年各大洲人口占比的甜甜圈图。

除了饼图和甜甜圈图,我们还可以用太阳爆炸图展示更为复杂的占比钻取分析。图 30 所示为 2007 年世界各大洲和国家占比的爆炸图。




图 29. 各大洲人口占比, 2007年, 甜甜圈图




图 30. 各大洲及各国人口占比, 2007年, 太阳爆炸图

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套徽课视频均发布在B站——生姜 DrGinger: https://space.bilibili.com/513194466

欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

图 31 用柱状图展示 2007 年人口超过 1 亿国家的具体人口数值。Bk6_Ch6_04.ipynb 还用 plotly.express.bar() 制作动画展示从 1952 年到 2007 年人口超过 1 亿国家及人口数变化。




图 31. 人口超过 1 亿的国家, 2007年, 柱状图

如图 32 所示,全球及各大洲人口都在增长,但是除了非洲以外的各大洲人口增速似乎放缓。这幅图展示的是人口数值变化,而图 33 采用的是百分比变化。图 33 更方便展示相对增速。

图 34 所示为人口异常变化 (5 年百分比变化) 的国家年份。




图 32. 各大洲人口每 5 年人口变化

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466




图 33. 各大洲人口每 5年人口变化百分比




图 34. 八百母 3 平日 7 儿支 化开口

人均 GDP

看完人口,再让我们看看人均 GDP 这列数据。

图 35 所示为全球各国人均 GDP 箱型图随年份变化;这幅图的纵轴为对数。

图 36 所示为各大洲人均 GDP 随年份变化,数值采用人口数量加权平均。

图 37 展示全球各国人均 GDP 每 5 年变化箱型图随年份变化。这幅图中我们已经发现了一些异常点,这些数据点都是是值得挖掘的"故事"。

在图 37 基础上, 图 38 用子图展示不同大洲的各国人均 GDP 每 5 年变化箱型图随年份变化。

类似图 34, Bk6_Ch6_04.ipynb 还可视化人均 GDP 变化异常的情况。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com




图 35. 全球各国人均 GDP 箱型图随年份变化




图 36. 各大洲人均 GDP (人口数量加权) 随年份变化




图 37. 全球各国人均 GDP 每 5 年变化箱型图随年份变化




图 38. 各大洲各国人均 GDP 每 5 年变化箱型图随年份变化

预期寿命

下面,让我们看看预期寿命这列数据,看看是否能发现任何有趣的趋势。

图 39 所示为全球各国预期寿命箱型图随年份变化,大家可能已经注意到 1992 年出现了似乎是离群的数据点,请大家到配套代码中检查这个数据点。

在图 39 基础上,图 40 用不同子图呈现各大洲各国预期寿命箱型图。

图 41 展示各大洲平均 (人口加权) 预期寿命随年份变化。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

配套代码还计算并可视化预期寿命异常变化情况。




图 39. 全球各国预期寿命箱型图随年份变化




图 40. 各大洲各国预期寿命箱型图随年份变化




图 41. 各大洲平均 (人口加权) 预期寿命随年份变化

人均 GDP、预期寿命存在的关系

最后,我们可以通过分析发现人均 GDP、预期寿命之间存在有趣的关系。图 42 用散点图展示 2007 年人均 GDP、预期寿命之间的关系。容易发现这样一种趋势,人均 GDP 越高,预期寿命越长。当然,这幅散点图也有一些可能存在的"离群点"值得我们逐一分析。比如,人均 GDP 较低,但是预期寿命相对较高的国家;人均 GDP 较高,但是预期寿命相对较低的国家。这些都是进一步挖掘的数据点。

配套代码文献还图 42 基础上做了动画,展示散点图随年份变化。

图 43 则是用不同子图展示不同大洲人均 GDP、预期寿命之间的关系,大家可以自行分析不同大洲之间在人均 GDP、预期寿命上的异同。图 44 在散点图基础上还绘制了边际箱型图,这幅图更容易分析不同大洲的差异。




图 42. 人均 GDP、预期寿命关系, 2007 年




图 43. 人均 GDP、预期寿命关系,标记大洲分图,2007 年




图 44. 人均 GDP、预期寿命关系,标记大洲,边际分布为箱型图,2007 年

图 45 用气泡图 (散点图的变形) 在人均 GDP、预期寿命平面上展示 2007 年数据; 再用散点大小展 示人口数量,用散点颜色展示大洲。注意,图 45 横轴取了对数。本章配套代码还制作了动画展示这幅图 随着年份变化。




图 45. 人均 GDP、预期寿命关系,气泡图,2007 年

图 46 所示三个国家在人均 GDP、预期寿命平面上,随着时间变化,人均 GDP 和预期寿命都呈现上升趋势。而图 47、图 48 却展现了截然不同的时间轨迹,请大家自行结合历史事件分析这两幅图像展现的轨迹。




图 46. 人均 GDP、预期寿命关系,加拿大、墨西哥、美国,时间轨迹




图 47. 人均 GDP、预期寿命关系,卢旺达,时间轨迹




图 48. 人均 GDP、预期寿命关系,柬埔寨,时间轨迹

图 49 所示为人均 GDP、预期寿命的非线性关系。图 50 所示为用非线性回归分析各大洲数据 2007 年数据;查看本章配套代码,大家可以发现横轴自变量数据先取对数后再进行回归分析。此外,图 50 有些子图中数据量不够回归分析,请大家采用所有年度数据(而不仅仅是 2007 年数据)再绘制类似图 50 散点图,并绘制趋势曲线。




图 49. 人均 GDP、预期寿命,非线性回归,2007 年




图 50. 人均 GDP、预期寿命、非线性回归、各大洲子图、2007年

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。版权归清华大学出版社所有,请勿商用,引用请注明出处。 代码及 PDF 文件下载: https://github.com/Visualize-ML 本书配套徽课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466 欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

图 51 所示为在人均 GDP、预期寿命平面上,根据样本数据位置用 k-Means 算法将它们聚类为 6 簇。k-Means 算法是一种无监督学习方法,用于将数据集分成 k 个聚类,通过迭代优化聚类中心,以最小化每个点到其最近聚类中心的距离,实现数据的聚类分析。



《机器学习》将介绍包括 k-Means 在内的各种聚类算法。




图 51. 人均 GDP、预期寿命,聚类,2007年



时间序列是按照时间顺序排列的数据点序列,通常用于描述随时间变化的现象,如股价、气温、销售额等。时间序列分析可以揭示数据的趋势、季节性和其他周期性模式。

时间序列数据中常常会出现缺失值,可能是由于数据采集过程中的错误、设备故障或其他原因导致的。处理缺失值的方法包括插值或者直接删除包含缺失值的时间点。

时间序列的趋势成分是指数据在长期内呈现的整体上升或下降的变化趋势。趋势成分反映了数据的 长期演变趋势,可以是线性的、非线性的、逐渐增长或减少的。

季节调整是为了消除时间序列中由于季节性变化引起的周期性模式。季节性通常是指在一年内某个固定时间范围内重复出现的模式,例如节假日、季节性销售高峰等。季节调整有助于更好地识别和理解时间序列中的趋势成分。处理时间序列数据时,常用的方法包括时间序列分解,将时间序列分解为趋势、季节性和残差等成分。这有助于更好地理解数据的结构,从而进行更准确的分析和预测。

本 PDF 文件为作者草稿,发布目的为方便读者在移动终端学习,终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有,请勿商用,引用请注明出处。

代码及 PDF 文件下载: https://github.com/Visualize-ML

本书配套微课视频均发布在 B 站——生姜 DrGinger: https://space.bilibili.com/513194466

欢迎大家批评指教,本书专属邮箱: jiang.visualize.ml@gmail.com

本章最后还回顾如何用"Pandas + Plotly"处理、可视化数据,并讲故事。